

復旦大學

K-hop 可达性查询

K-Reach 论文分析与阈值支配剪枝

第十三组

《图数据管理与挖掘》课程期中汇报

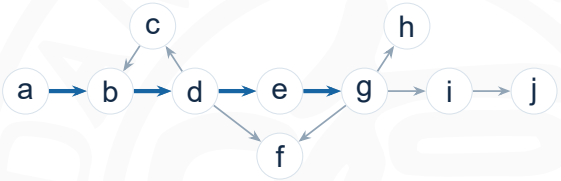
研究背景与问题定义

社交关系分析、信任关系检索等任务，常需要限制关系链的长度。对大量重复查询，逐次运行 BFS 会反复访问相同的局部结构。

K-hop 可达性查询

给定有向无权图 $G = (V, E)$、节点 s, t 和跳数上限 k，判断是否存在至多 k 条边的路径：

$$Q(s, t, k) = [d_G(s, t) \le k].$$



$d(a, g) = 4$

$k = 3$：不可达　　$k = 4$：可达

K-Reach 的研究思路与框架

K-Reach: Who is in Your Small World

James Cheng, Zechao Shang, Hong Cheng, Haixun Wang, Jeffrey Xu Yu

PVLDB 5(11):1292–1303, 2012.

论文通过顶点覆盖，将任意端点的跳数查询转化为核心节点之间的距离判定。

顶点覆盖

选择核心集合，使覆盖外端点一跳接入核心。

→

三档距离索引

保存 $k-2$、$k-1$、k 三个阈值需要的信息。

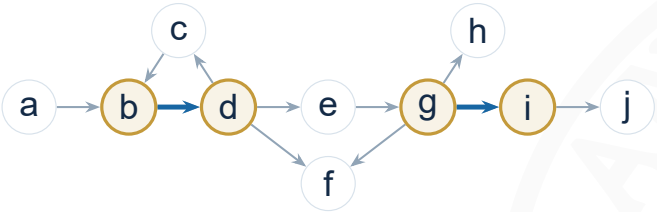
→

四类查询

根据起点和终点是否在核心中，选择查询方式。

这种设计兼顾了索引规模与查询效率，避免保存所有完整距离。

关键技术一：用顶点覆盖连接查询端点



覆盖集合 $S = \{b, d, g, i\}$

顶点覆盖要求每条边至少一端在 S。

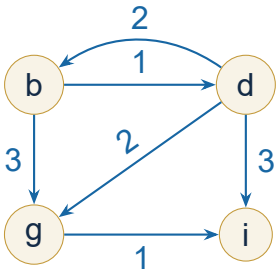
因此，覆盖外节点之间没有边：

$$s \notin S \Rightarrow N^+(s) \subseteq S,$$

$$t \notin S \Rightarrow N^-(t) \subseteq S.$$

论文采用极大匹配的全部端点构造 2-近似顶点覆盖。查询两端各用至多一跳，即可连接到核心。

关键技术二：三档距离索引



$k = 3$ 时的核心索引，省略自环。

核心距离	保存的权重	两位码
$d \le k-2$	$k-2$	01
$d = k-1$	$k-1$	10
$d = k$	k	11
$d > k$ / 不可达	无索引边	00

从各核心节点在原图运行 k 限制 BFS，预先构建索引。

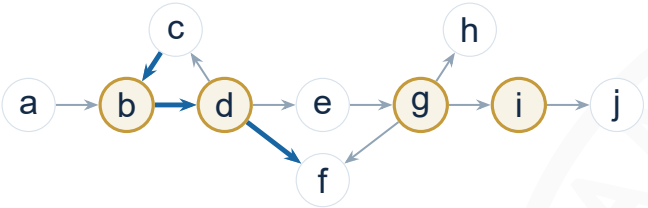
编码依据：端点接入核心各占 0 或 1 跳，剩余预算只有 k、$k-1$ 和 $k-2$，因此三档信息足以完成判定。

四类查询及其核心距离预算

端点位置	查询的核心点对	距离预算
两点都在 S	(s,t)	k
仅 $s \in S$	(s,v)，$v \in N^-(t)$	$k-1$
仅 $t \in S$	(u,t)，$u \in N^+(s)$	$k-1$
两点都不在 S	(u,v)，$u \in N^+(s)$、$v \in N^-(t)$	$k-2$

对相应核心点对进行检查；只要存在一对满足预算，查询即返回 True。

查询示例：判断 c 能否在三跳内到达 f



$$c \xrightarrow{1} b \xrightarrow{1} d \xrightarrow{1} f$$

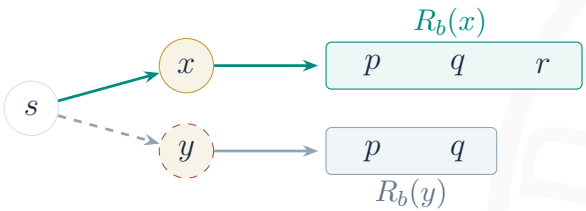
1. $c, f \notin S$，属于第四类。
2. 两端各占一跳，核心预算为 $3 - 2 = 1$。
3. $d(b, d) = 1$，满足预算，返回 True。

若终点改为 h，则需检查核心点对 (b, g)。其距离为 3，超过预算 1，因此返回 False。

当端点连接多个覆盖邻居时，算法仍需枚举这些邻居。我们接下来研究其中可以消去的冗余候选。

改进思路：消去冗余的边界候选

将覆盖外端点与核心相连的邻居集合称为**查询边界**。如果一个邻居可达的目标已被另一个邻居覆盖，就可以减少一次候选枚举。



阈值支配

$R_b(u)$ 表示 u 在预算 b 内可达的核心节点集。若

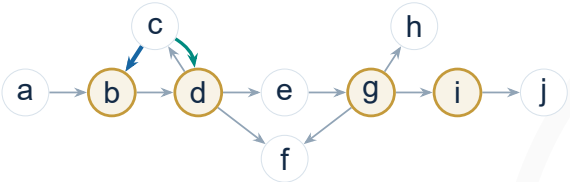
$$R_b(y) \subseteq R_b(x),$$

则 y 可由 x 替代。

出边界比较后继集合，入边界比较前驱集合；约简后仍按原文四类规则完成查询。

关键技术：区分跳数预算与边界方向

$k = 3$ 的示例：在论文图中增加一条 $c \to d$



新增边用青色标记，$N^+(c) = \{b, d\}$。

预算	$R(b)$	$R(d)$	保留
1	$\{b, d\}$	$\{d\}$	b
2	$\{b, d\}$	$\{b, d, g\}$	d

$c \to g$ 属于第三类查询，预算为 2，需保留 d；沿用预算 1 的代表 b 会漏判。

实现框架

离线保存两个预算、两个方向的约简边界；在线按查询类别选取相应列表。

实验设置

有向图	节点	边
Wiki-Vote	7,115	103,689
Gnutella31	62,586	147,892
Email-EuAll	265,214	418,956

$k = 2, 4, 6$，主结果取 $k = 4$。
均匀查询、正负平衡查询。
每批 5,000 条，3 个随机种子。

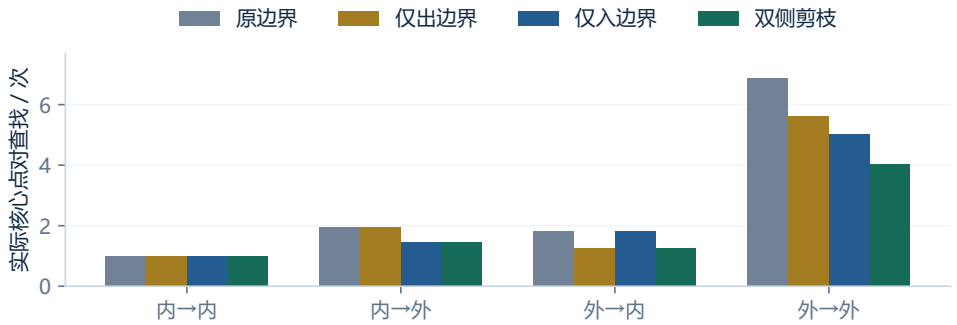
对比方案

- 原始边界：CSR、混合编码、有序表求交。
- 改进：将双侧支配剪枝与上述表示结合。
- 消融：仅约简出边界或入边界。

共比较 8 种方案，每种重复计时 9 次。所有查询结果与完整 BFS 一致。

核心查找次数与消融结果

Wiki-Vote，$k = 4$，正负平衡查询

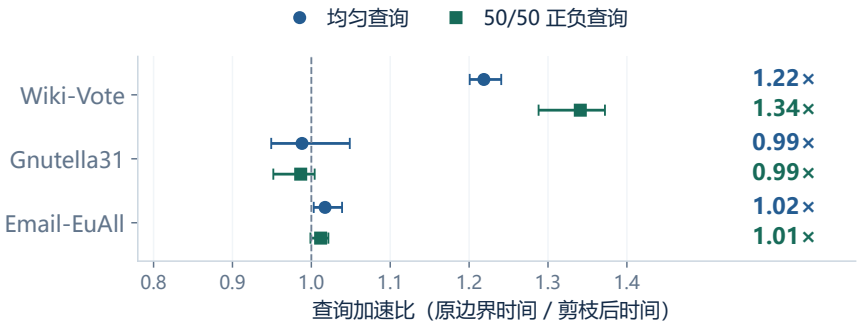


双侧剪枝将平均核心查找由 2.01 次降至 1.43 次，减少 29%。

两端均在覆盖内时，查找过程保持不变。

查询性能与额外开销

$k = 4$，在相同混合编码下比较剪枝前后



Wiki 上平均加速 1.28 倍；P2P 和 Email 的查询时间变化较小。

Wiki 增加约 70 KiB 边界索引，构建约 0.10s。

总结与创新点

论文的主要贡献

用顶点覆盖连接任意查询端点，以三档距离信息支持四类精确查询，在索引规模和查询效率之间取得平衡。

我们的改进

按有限跳数下的集合支配约简查询边界，为两个预算、两个方向分别保存代表，并通过见证替代保持精确判定。

实验表明，该方法在冗余边界较多的 Wiki 上减少了核心查找，并获得约 1.28 倍查询加速。

后续可以优化边界构建的暂存空间，并结合构建开销选择适合启用剪枝的节点。

谢谢

参考文献

1. J. Cheng, Z. Shang, H. Cheng, H. Wang, J. X. Yu. **K-Reach: Who is in Your Small World.** *PVLDB* 5(11):1292–1303, 2012. doi:10.14778/2350229.2350247.
2. X. Tang, J. Zhou, Y. Shi, X. Liu, K. Lin. **Efficient Processing of k-Hop Reachability Queries on Directed Graphs.** *Applied Sciences* 13(6):3470, 2023. doi:10.3390/app13063470.
3. C. Zhang, A. Bonifati, M. T. Özsu. **Indexing Techniques for Graph Reachability Queries.** *ACM CSUR* 58(6), Article 156, 2026; online Dec. 2025. doi:10.1145/3776737.
4. J. Leskovec, A. Krevl. **SNAP Datasets**. snap.stanford.edu/data/.