

復旦大學

K-hop 可达性查询

K-Reach 论文分析与阈值支配剪枝

第十三组

《图数据管理与挖掘》课程期中汇报

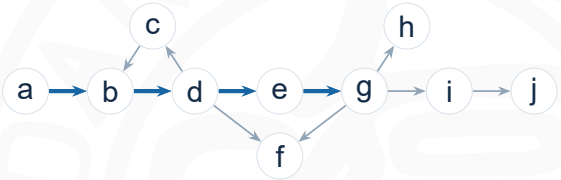
研究背景与问题定义

社交关系分析、信任关系检索等任务，常需要限制关系链的长度。对大量重复查询，逐次运行 BFS 会反复访问相同的局部结构。

K-hop 可达性查询

给定有向无权图 $G = (V, E)$、节点 s, t 和跳数上限 k，判断是否存在至多 k 条边的路径：

$$Q(s, t, k) = [d_G(s, t) \le k].$$



$d(a, g) = 4$

$k = 3$：不可达　　$k = 4$：可达

K-Reach 的研究思路与框架

K-Reach: Who is in Your Small World

James Cheng, Zechao Shang, Hong Cheng, Haixun Wang, Jeffrey Xu Yu

PVLDB 5(11):1292–1303, 2012.

论文通过顶点覆盖，将任意端点的跳数查询转化为核心节点之间的距离判定。

顶点覆盖

选择核心集合，使覆盖外端点一跳接入核心。

→

三档距离索引

保存 $k-2$、$k-1$、k 三个阈值需要的信息。

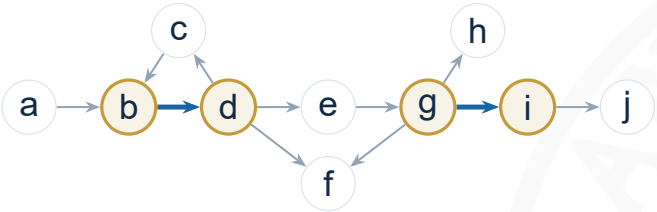
→

四类查询

根据起点和终点是否在核心中，选择查询方式。

这种设计兼顾了索引规模与查询效率，避免保存所有完整距离。

关键技术一：用顶点覆盖连接查询端点



覆盖集合 $S = \{b, d, g, i\}$

顶点覆盖要求每条边至少一端在 S。

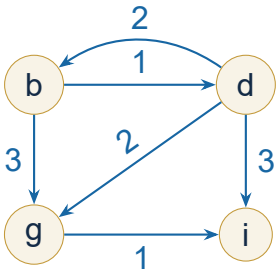
因此，覆盖外节点之间没有边：

$$s \notin S \Rightarrow N^+(s) \subseteq S,$$

$$t \notin S \Rightarrow N^-(t) \subseteq S.$$

论文采用极大匹配的全部端点构造 2-近似顶点覆盖。查询两端各用至多一跳，即可连接到核心。

关键技术二：三档距离索引



$k = 3$ 时的核心索引，省略自环。

核心距离	保存的权重	两位码
$d \le k-2$	$k-2$	01
$d = k-1$	$k-1$	10
$d = k$	k	11
$d > k$ / 不可达	无索引边	00

从各核心节点在原图运行 k 限制 BFS，预先构建索引。

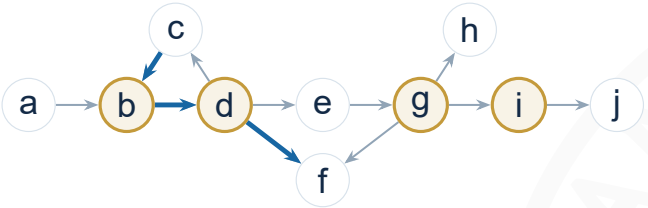
编码依据：端点接入核心各占 0 或 1 跳，剩余预算只有 k、$k-1$ 和 $k-2$，因此三档信息足以完成判定。

四类查询及其核心距离预算

端点位置	查询的核心点对	距离预算
两点都在 S	(s,t)	k
仅 $s \in S$	(s,v)，$v \in N^-(t)$	$k-1$
仅 $t \in S$	(u,t)，$u \in N^+(s)$	$k-1$
两点都不在 S	(u,v)，$u \in N^+(s)$、$v \in N^-(t)$	$k-2$

对相应核心点对进行检查；只要存在一对满足预算，查询即返回 True。

查询示例：判断 c 能否在三跳内到达 f



$$c \xrightarrow{1} b \xrightarrow{1} d \xrightarrow{1} f$$

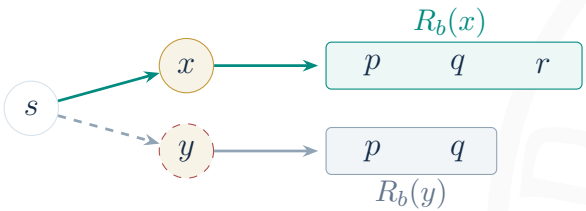
1. $c, f \notin S$，属于第四类。
2. 两端各占一跳，核心预算为 $3 - 2 = 1$。
3. $d(b, d) = 1$，满足预算，返回 True。

若终点改为 h，则需检查核心点对 (b, g)。其距离为 3，超过预算 1，因此返回 False。

当端点连接多个覆盖邻居时，算法仍需枚举这些邻居。我们接下来研究其中可以消去的冗余候选。

改进思路：消去冗余的边界候选

将覆盖外端点与核心相连的邻居集合称为**查询边界**。如果一个邻居可达的目标已被另一个邻居覆盖，就可以减少一次候选枚举。



阈值支配

$R_b(u)$ 表示 u 在预算 b 内可达的核心节点集。若

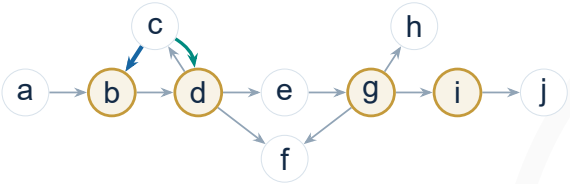
$$R_b(y) \subseteq R_b(x),$$

则 y 可由 x 替代。

出边界比较后继集合，入边界比较前驱集合；约简后仍按原文四类规则完成查询。

关键技术：区分跳数预算与边界方向

$k = 3$ 的示例：在论文图中增加一条 $c \to d$



新增边用青色标记，$N^+(c) = \{b, d\}$。

预算	$R(b)$	$R(d)$	保留
1	$\{b, d\}$	$\{d\}$	b
2	$\{b, d\}$	$\{b, d, g\}$	d

$c \to g$ 属于第三类查询，预算为 2，需保留 d；沿用预算 1 的代表 b 会漏判。

实现框架

离线保存两个预算、两个方向的约简边界；在线按查询类别选取相应列表。

实验设置

有向图	节点	边
Wiki-Vote	7,115	103,689
Gnutella31	62,586	147,892
Email-EuAll	265,214	418,956

$k = 2, 4, 6$，主结果取 $k = 4$。
均匀查询、正负平衡查询。
每批 5,000 条，3 个随机种子。

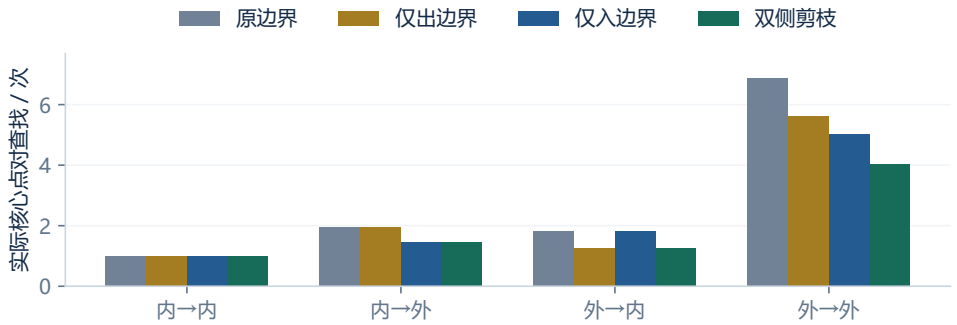
对比方案

- 原始边界：CSR、混合编码、有序表求交。
- 改进：将双侧支配剪枝与上述表示结合。
- 消融：仅约简出边界或入边界。

共比较 8 种方案，每种重复计时 9 次。所有查询结果与完整 BFS 一致。

核心查找次数与消融结果

Wiki-Vote，$k = 4$，正负平衡查询

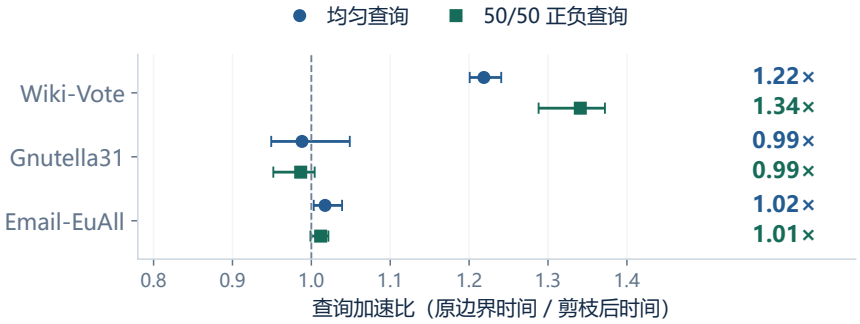


双侧剪枝将平均核心查找由 2.01 次降至 1.43 次，减少 29%。

两端均在覆盖内时，查找过程保持不变。

查询性能与额外开销

$k = 4$，在相同混合编码下比较剪枝前后



Wiki 上平均加速 1.28 倍；P2P 和 Email 的查询时间变化较小。

Wiki 增加约 70 KiB 边界索引，构建约 0.10s。

总结与创新点

论文的主要贡献

用顶点覆盖连接任意查询端点，以三档距离信息支持四类精确查询，在索引规模和查询效率之间取得平衡。

我们的改进

按有限跳数下的集合支配约简查询边界，为两个预算、两个方向分别保存代表，并通过见证替代保持精确判定。

实验表明，该方法在冗余边界较多的 Wiki 上减少了核心查找，并获得约 1.28 倍查询加速。

后续可以优化边界构建的暂存空间，并结合构建开销选择适合启用剪枝的节点。

谢谢

附录 A •四类查询的正确性

充分性：核心距离不超过 $k-a-b$，接回起点与终点的 $a,b \in \{0,1\}$ 跳边，就得到长度不超过 k 的行走；去环后仍有合法路径。

必要性：合法路径的覆盖外起点首步必进入 S，覆盖外终点末步必来自 S。因此路径必经四类查询枚举的一对核心点，其最短核心距离满足剩余预算。

边界处理：先处理 $s=t$；核心对角线保留零距离。两个外部端点共享一个核心邻居时也能正确接受。$k=1$ 可直接查边，本项目索引实验使用 $k \geq 2$。

任意合法路径均对应一个满足预算的核心点对。

附录 B •固定 k 的索引与多 k 查询

假设在 $k = 6$ 时建索引：

$d(u, v) = 2$ 与 $d(u, v) = 4$ 都编码成 **01**，即“$d \le 4$”。

改问 $k = 3$ 时，两者答案不同，原码却无法区分。

原文 §4.4 讨论多 k 的扩展；保存完整核心距离与三档码是不同设计。本项目 $k = 2, 4, 6$ 分别编码，也分别构造预算相关边界。

固定 k 下仍须区分两个预算：**Case 2/3 用 $k - 1$，Case 4 用 $k - 2$**。

附录 C •原文 (h, k)-Reach 的空间—时间取舍

h-hop 顶点覆盖：每条长度为 h 的路径至少含一个覆盖点。核心可以更小，但外部端点可能要走 $1 \dots h$ 跳接入核心。

核心预算相应变为 $k - i - j$，需要保留更多距离阈值；原文定义给出 $h < k/2$。

Nasa 的 $h = 2, \mu = 7$ 满足条件：覆盖 $1841 \to 1223$，百万查询从 $18.23 \to 39.48$ms。μ 为图上最短路径长度中位数。

更小的覆盖减少索引规模，同时增加端点接入核心的搜索开销。

附录 D ·核心编码是对照因素，单独控制

原文 §4.3 已讨论压缩。我们实现两位类别打包 CSR 与按行稀疏/稠密的 Hybrid，用作物理表示对照；**主图比较相同 Hybrid 上剪枝前后。**

稀疏行载荷约 $4r + \lceil r/4 \rceil$ 字节，稠密行 $\lceil |S|/4 \rceil$ 字节。计入元数据后，混合布局不如两种全局格式时整体回退。

原边界在所有新对照中均预先转为核心 ID，使用相同答案核。CSR 求交另有原边界和剪枝边界两个版本。

分别比较相同编码和相同查询方式下的剪枝效果。

附录 E ·部署空间、证书暂存与预处理分摊

图	原边界/MiB	剪枝/MiB	总部署/MiB	构建/s	证书/MiB
Wiki-Vote	0.10	0.17	2.01	0.10	2.52
Gnutella31	0.71	1.42	22.99	2.23	155.47
Email-EuAll	3.37	6.63	34.74	5.04	314.92

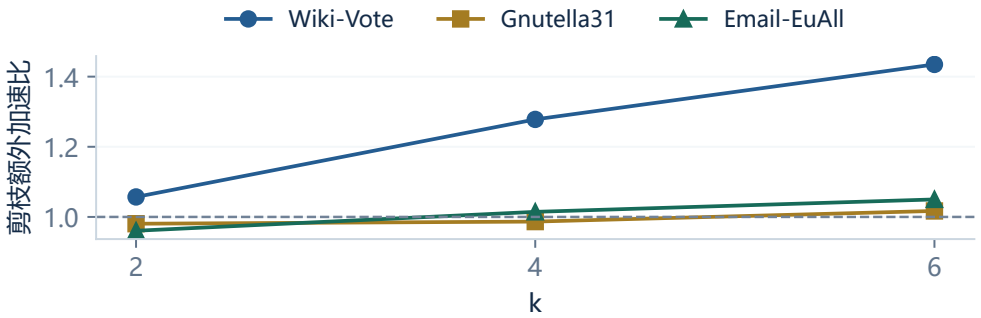
总部署包含核心索引、节点映射和边界。证书用于离线构建，完成后可释放。Email 的核心距离暂存矩阵约为 1.23 GiB。

原边界两个预算复用数组；剪枝后的预算列表分别保存，因此可能增加空间。

面向静态图上的重复查询，**预处理与额外存储是明确代价**。

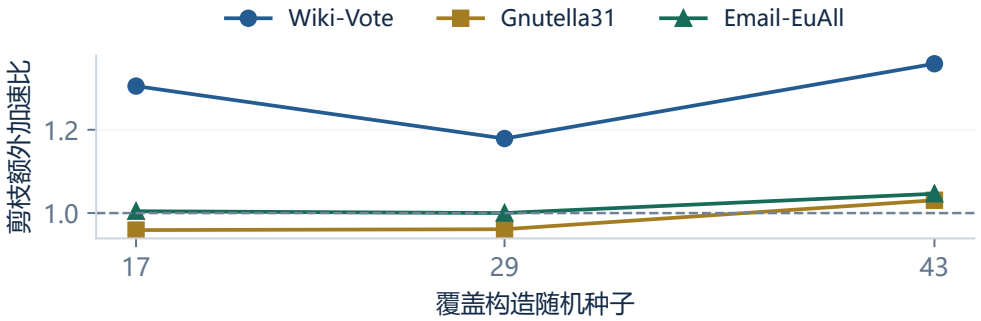
Wiki $k = 4$：按构建时间 0.10s 与当前平均查询节省估算，约 1.92 百万次查询可分摊构建开销。

附录 F •不同 k 下，结构相关收益也会变化



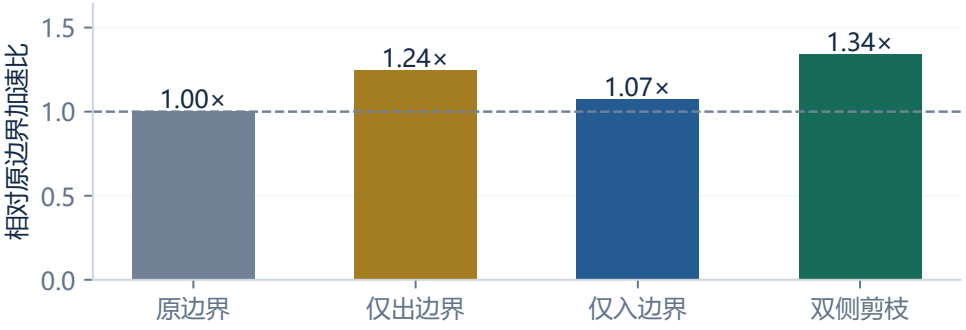
每个 k 分别建立两层预算边界；收益受阈值包含关系与原始查询工作共同影响。

附录 G ·更换覆盖构造，结论是否只依赖一次选择?



覆盖种子 17 / 29 / 43 全部保留，未按测试计时挑选覆盖；Wiki 在三次覆盖下均有收益。

附录 H •单侧与双侧剪枝的时间消融



出、入边界贡献不同；双侧同时保留阈值见证，再由实际计时判断整体收益。

附录 I •所有图与 k 的完整查询结果

图	k	Join	+ 剪枝	加速	Hybrid	+ 剪枝	加速
Wiki-Vote	2	0.550	0.557	0.99	0.425	0.403	1.06
Wiki-Vote	4	0.429	0.379	1.13	0.246	0.191	1.28
Wiki-Vote	6	0.363	0.302	1.20	0.212	0.145	1.43
Gnutella31	2	0.263	0.262	1.00	0.281	0.287	0.98
Gnutella31	4	0.344	0.349	0.98	0.357	0.361	0.99
Gnutella31	6	0.516	0.516	1.00	0.272	0.267	1.02
Email-EuAll	2	0.416	0.423	0.98	0.420	0.437	0.96
Email-EuAll	4	0.366	0.379	0.97	0.251	0.247	1.01
Email-EuAll	6	0.339	0.333	1.02	0.232	0.221	1.05

时间单位：μs/查询。Join / Hybrid 各自配对比较，避免把换编码的收益算到剪枝上。

附录 J •后续研究与本项目分别优化什么?

VCRea / VCRea^{+}（Tang 等，2023）

以顶点覆盖构造两跳距离标签，给高出度点扩展 out-label、高入度点扩展 in-label，将标签对比较次数限制在至多 d^2。增加标签是一种空间与枚举代价取舍。

阈值支配剪枝（本项目）

不增加距离精度，按现有两档阈值集合的包含关系消去冗余邻居；代价是边界构建及额外列表。

近期 CSUR 综述单列 hop-constrained 语义，说明普通可达索引不能直接替代跳数约束。

VCRea 扩展距离标签；本项目研究固定 K-Reach 索引上的边界约简。

附录 K ·双侧约简的正确性

原出/入边界为 A, B，保留代表为 A', B'。任意合法核心对 (y, v)，满足 $d(y, v) \le b$。

替代源侧：有 $x \in A'$，使 $R_b(y) \subseteq R_b(x)$。因此 $v \in R_b(x)$，即 $d(x, v) \le b$。

替代终侧：有 $v' \in B'$，使 $L_b(v) \subseteq L_b(v')$。既然 $x \in L_b(v)$，就有 $d(x, v') \le b$。

保留边界又是原边界的子集，所以不存在新增的错误成功见证。单侧分支只做相应的一次替代。

两侧必须用**相同剩余预算**，且终侧用前驱集合；普通可达或任意 SCC 代表不满足此条件。

附录 L •构建方法与查找次数的变化

按集合大小降序处理邻居；已被保留集合包含就消去。反射性给出必要条件：

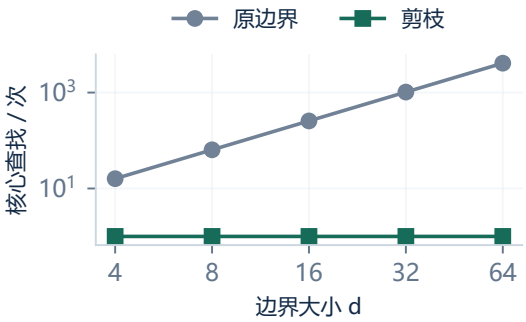
$$R_b(y) \subseteq R_b(x) \;\Rightarrow\; d(x,y) \le b.$$

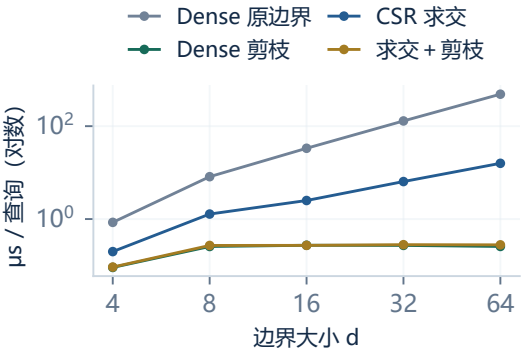
先做该常数检查，再验证位集合包含。真实图审计使用**直接整数距离**逐项核对被消去者与其保留代表，独立于位打包构建。

潜在候选上界不会增加，但找到成功见证的顺序可能变化。主实验及覆盖补充中，有 5 条查询的实际查找次数增加。

代表点可能出现在更后的位置，因此部分查询会在更多次检查后找到成功见证。

附录 M ·受控合成图上的机制验证





嵌套边界负例：原查找 d^2 次，约简后 1 次。**固定全稠密 lookup 也有候选增长问题。**

参考文献

1. J. Cheng, Z. Shang, H. Cheng, H. Wang, J. X. Yu. **K-Reach: Who is in Your Small World.** *PVLDB* 5(11):1292–1303, 2012. doi:10.14778/2350229.2350247.

2. X. Tang, J. Zhou, Y. Shi, X. Liu, K. Lin. **Efficient Processing of k-Hop Reachability Queries on Directed Graphs.** *Applied Sciences* 13(6):3470, 2023. doi:10.3390/app13063470.

3. C. Zhang, A. Bonifati, M. T. Özsu. **Indexing Techniques for Graph Reachability Queries.** *ACM CSUR* 58(6), Article 156, 2026; online Dec. 2025. doi:10.1145/3776737.

4. J. Leskovec, A. Krevl. **SNAP Datasets**. snap.stanford.edu/data/.